



Universidad de Castilla-La Mancha

Escuela Superior de Ingeniería Informática de Albacete

Escuela Superior de Informática de Ciudad Real

Trabajo Fin de Máster

Máster Universitario en Ingeniería Informática

Simulador web de escenarios de movilidad urbana mediante técnicas de Inteligencia Artificial

Iván Vicente Hernández García de Mora

Noviembre, 2025

TRABAJO FIN DE MÁSTER

Máster Universitario en Ingeniería Informática

Simulador web de escenarios de movilidad urbana mediante técnicas de Inteligencia Artificial

Autor: Iván Vicente Hernández García de Mora

Director: Nombre del director

Codirector: Nombre del codirector

*Aquí va la dedicatoria que cada cual
quiera escribir. El ancho se controla
manualmente*

Declaración de autoría

Yo, ... , con DNI ... , declaro que soy el único autor del trabajo fin de grado titulado “ ... ”, que el citado trabajo no infringe las leyes en vigor sobre propiedad intelectual, y que todo el material no original contenido en dicho trabajo está apropiadamente atribuido a sus legítimos autores.

Albacete, a ... de ... de 20 ...

Fdo.: Iván Vicente Hernández García de Mora

Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Agradecimientos

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Índice general

1	Introducción	1
1.1	Contexto y motivación	1
1.2	Objetivos del TFM	1
1.2.1	<i>Objetivo general</i>	1
1.2.2	<i>Objetivos específicos</i>	1
1.2.3	<i>Competencias trabajadas</i>	2
1.3	Alcance y limitaciones	2
2	Estado del arte y marco tecnológico	3
2.1	Fundamentos y enfoques	3
2.2	Datos abiertos para movilidad	3
2.2.1	<i>OpenStreetMap</i>	4
2.2.2	<i>GTFS</i>	4
2.3	Tecnologías abiertas de enrutado	5
2.3.1	<i>OSRM</i>	6
2.3.2	<i>OpenTripPlanner</i>	6
2.4	Plataformas propietarias y servicios gestionados	7
2.4.1	<i>Google Maps Platform</i>	7
2.4.2	<i>Otras plataformas de referencia</i>	8
2.5	Modelado de elección modal	8
2.5.1	<i>Modelos de utilidad aleatoria</i>	9
2.5.2	<i>Modelo Logit Multinomial</i>	10
2.5.3	<i>Limitaciones del enfoque clásico</i>	12
2.5.4	<i>Aprendizaje automático para elección modal</i>	12
2.5.5	<i>Random Forests</i>	13

2.5.6	<i>Gradient Boosting Decision Trees</i>	14
2.5.7	<i>Redes Neuronales Profundas</i>	15
3	Metodología	17
3.1	SCRUM adaptado a un desarrollo unipersonal	17
3.2	Product Backlog	20
3.2.1	<i>Backlog inicial</i>	20
3.2.2	<i>Priorización de items</i>	21
3.3	Histórico de sprints ejecutados	21
3.3.1	<i>Sprint 1: Validación inicial de OSRM mediante servicios remotos</i>	22
3.3.2	<i>Sprint 2: Despliegue del servicio OSRM local multi-perfil</i>	23
3.3.3	<i>Sprint 3: Incorporación del GTFS urbano de Toledo</i>	23
3.3.4	<i>Sprint 4: Integración de OpenTripPlanner para rutas multimodales</i>	24
3.3.5	<i>Sprint 5: Diseño de la interfaz web y codificación visual por modo</i>	24
3.3.6	<i>Sprint 6: Diseño de un modelo de clasificación de modo de viaje y procesado de datos</i>	25
3.3.7	<i>Sprint 7: Entrenamiento y validación de los modelos de clasificación</i>	25
3.3.8	<i>Sprint 8: Escritura de la memoria y consolidación metodológica</i>	25
3.3.9	<i>Sprint 9: Integración del módulo de inferencia en el simulador</i>	26
3.4	Cierre del ciclo de desarrollo	26
4	Arquitectura del sistema	27
4.1	Visión general.	27
4.2	Infraestructura y orquestación	28
4.3	Backend: capa de orquestación.	29
4.4	Frontend: interfaz cartográfica	30
4.5	Pipeline de inferencia modal	31
4.6	Decisiones técnicas (ch5).	33
5	Implementación y resultados	35
5.1	Implementación de OSRM local.	35
5.1.1	<i>Preprocesado por perfiles</i>	35
5.1.2	<i>Despliegue de contenedores</i>	35
5.2	Implementación de OTP con Toledo	35
5.2.1	<i>Construcción de grafo</i>	35
5.2.2	<i>Explotación del planificador</i>	35

5.3	Implementación del backend.	35
5.3.1	Endpoints y servicios.	35
5.4	Implementación del frontend.	36
5.4.1	Interfaz y mapa interactivo.	36
5.5	Integración de datos GTFS.	36
5.5.1	Carga y procesamiento.	36
5.6	Entrenamiento de los modelos de aprendizaje automático.	36
5.6.1	Descripción del dataset.	36
5.6.2	Preprocesado de datos.	36
5.6.3	Ajuste de hiperparámetros.	36
5.6.4	Entrenamiento y evaluación.	36
6	Conclusiones y trabajo futuro.	39
6.1	Conclusiones técnicas.	39
6.2	Cumplimiento de objetivos.	39
6.3	Trabajo futuro.	39
A	Anexos.	41
A.1	Manual de despliegue y ejecución.	41
A.1.1	Requisitos del entorno.	41
A.1.2	Arranque de servicios.	41
A.2	Endpoints y contratos API.	41
A.2.1	Contratos del backend.	41
A.3	Tablas de hiperparámetros y resultados completos.	41
A.3.1	Configuraciones experimentales.	41
A.4	Evidencias de sprints.	41
A.4.1	Registro de tareas y decisiones.	42

Índice de figuras

2.1	Forma sigmoideal ilustrativa de la probabilidad de elección en el modelo MNL. Elaboración propia.	11
3.1	Esquema del ciclo de trabajo SCRUM adaptado al desarrollo unipersonal del proyecto. Elaboración propia.	19
3.2	Cronograma aproximado de los sprints ejecutados durante el desarrollo del TFM, representado como diagrama de Gantt simplificado. Elaboración propia.	22
4.1	Arquitectura general del simulador de movilidad urbana.	28
4.2	Pipeline de inferencia de elección modal.	31

Índice de tablas

- 2.1 Comparación resumida de las soluciones de enrutado consideradas en este trabajo. Elaboración propia a partir de [?, ?, ?, ?]. 8
- 4.1 Servicios Docker Compose del simulador. 28
- 4.2 Endpoints principales de la API REST del backend. 29
- 4.3 Variables de entrada al modelo de elección modal. Las variables de ruta se derivan automáticamente de OSRM y OTP; las sociodemográficas las aporta el usuario. 32
- 5.1 Resultados en entrenamiento con validación cruzada de 5-folds agrupada por hogar (dataset LPMC) 36
- 5.2 Resultados en el conjunto de test (dataset LPMC) 37

Índice de algoritmos

Índice de listados de código

1. Introducción

1.1. Contexto y motivación

1.2. Objetivos del TFM

1.2.1. Objetivo general

Desarrollar un prototipo de simulador web de movilidad urbana que integre modelos de predicción basados en Machine Learning y servicios de enrutado, con el fin de analizar el impacto de distintas políticas de transporte en el reparto modal de los viajes y generar métricas de apoyo para la planificación y la toma de decisiones.

1.2.2. Objetivos específicos

- Entrenar y validar modelos de Machine Learning con datos de movilidad para predecir la elección modal de los usuarios en función de variables sociodemográficas, de tiempo y de coste.
- Integrar servicios de enrutado (OSRM y OpenTripPlanner) para obtener tiempos y costes realistas entre pares origen-destino en el entorno urbano.
- Desarrollar una aplicación web interactiva que permita definir viajes sobre un mapa, simular el comportamiento de los usuarios y visualizar resultados en un cuadro de mando.
- Implementar un módulo de análisis de escenarios *what-if* para modificar parámetros de política (coste del coche, tarifas del transporte público, frecuencia de autobuses, etc.) y observar su efecto en el reparto modal.

-
- Generar métricas de impacto (reparto modal, tiempo medio de viaje y estimación de emisiones de CO₂) como apoyo a la toma de decisiones en movilidad urbana.

1.2.3. Competencias trabajadas

El desarrollo del TFM contribuye a las siguientes competencias del Máster:

- **CP01:** Integrar tecnologías, aplicaciones, servicios y sistemas de la Ingeniería Informática en un contexto multidisciplinar.
- **CP05:** Aplicar métodos matemáticos, estadísticos y de inteligencia artificial para modelar y desarrollar sistemas inteligentes.
- **CP07:** Realizar un proyecto integral original de carácter profesional que sintetice las competencias adquiridas en el plan de estudios.

1.3. Alcance y limitaciones

2. Estado del arte y marco tecnológico

2.1. Fundamentos y enfoques

La movilidad urbana se ha consolidado como un ámbito de estudio en el que confluyen la ingeniería del transporte, la analítica de datos y la inteligencia artificial. En este contexto, los simuladores actuales no se limitan a representar mapas o a calcular rutas aisladas, sino que actúan como herramientas para evaluar políticas y escenarios de movilidad, permitiendo analizar de forma anticipada cómo cambios en los costes, en la oferta de transporte o en las condiciones operativas pueden modificar el comportamiento de la población.

Este tipo de sistemas exige combinar varias capas de conocimiento. Por un lado, la capa de datos, que determina la calidad y la trazabilidad de la información sobre la red de transporte y los servicios de transporte público asociados. Por otro, la capa de enrutado, que permite transformar un par origen-destino en variables de servicio observables (tiempo, distancia, segmentos de viaje, transbordos o coste aproximado). Finalmente, la capa de modelado, en la que dichas variables se integran con atributos sociodemográficos para estimar la elección modal y construir escenarios *what-if*. Esta arquitectura en capas es coherente con la evolución reciente de herramientas de simulación en investigación y planificación [?, ?].

2.2. Datos abiertos para movilidad

El desarrollo de los sistemas descritos en el apartado anterior requiere la disponibilidad de grandes volúmenes de datos fiables y reutilizables. Por este motivo, en los últimos años han adquirido gran protagonismo los conjuntos de datos abiertos en movilidad, ya que

permiten construir, validar y reproducir modelos de análisis sin depender de fuentes propietarias cerradas. En este contexto, OpenStreetMap y GTFS se han consolidado como los dos pilares más utilizados para representar, respectivamente, la red urbana y la oferta de transporte público.

2.2.1. OpenStreetMap

OpenStreetMap (OSM) es una base de datos geográfica abierta y colaborativa ampliamente utilizada en proyectos de movilidad, tanto en investigación como en aplicaciones operativas. La propia fundación del proyecto define OSM como una fuente de datos abiertos reutilizable por terceros, con cobertura global y actualización continua por parte de la comunidad [?]. Esta naturaleza abierta resulta especialmente relevante en un trabajo experimental, ya que permite reproducir resultados a partir de un conjunto de datos público, versionable e independiente de condiciones comerciales impuestas por terceros.

En términos de calidad cartográfica, diversos estudios han mostrado que OSM puede ofrecer niveles de precisión adecuados para el análisis del transporte, aunque con cierta heterogeneidad espacial entre zonas y entre tipos de elemento, por ejemplo, entre la red viaria principal y los detalles de la infraestructura peatonal [?]. Por ello, en este trabajo OSM se considera una fuente adecuada para construir la red de enrutado, teniendo en cuenta las características específicas del área de estudio al interpretar los resultados.

2.2.2. GTFS

GTFS (*General Transit Feed Specification*) es el estándar abierto dominante para publicar oferta de transporte público programada. La documentación oficial describe de forma precisa el contrato de datos entre productor y consumidor: estructura de ficheros, relaciones entre entidades y restricciones semánticas necesarias para que un planificador pueda reconstruir correctamente servicios, horarios y calendarios [?]. En otras palabras, GTFS no es solo un formato de intercambio, sino también un marco común de interoperabilidad entre operadores, agregadores y motores de planificación.

La estructura del estándar se basa en un conjunto de ficheros fundamentales, entre los que destacan `stops.txt`, `routes.txt`, `trips.txt`, `stop_times.txt`, `calendar.txt` y `calendar_dates.txt`. Estos archivos permiten representar simultáneamente la topología de la red y la dimensión temporal del servicio [?]. Esta separación resulta esencial, ya que el componente espacial define dónde se presta el servicio y el componente temporal determina cuándo se presta. En un entorno de simulación multimodal, ambos planos deben

mantenerse coherentes para evitar itinerarios inviables o resultados inconsistentes.

En el contexto español, el canal institucional más relevante para localizar y descargar feeds GTFS es el *Punto de Acceso Nacional de Transporte Multimodal* (NAP), gestionado por el Ministerio de Transportes y Movilidad Sostenible. La propia descripción oficial del portal lo define como el punto único nacional para concentrar información de oferta de transporte de viajeros, en línea con el marco europeo de datos de movilidad [?, ?].

En este TFM, la descarga de datos para transporte urbano se realizó precisamente desde NAP. Como ejemplo de referencia nacional se consultó el conjunto de EMT Valencia y, para el caso de estudio del proyecto, el conjunto de autobuses urbanos de Toledo [?, ?]. En ambos casos, la página de detalle expone metadatos operativos (por ejemplo, número de paradas y formatos de descarga), así como los atributos incluidos en el conjunto de datos, como la accesibilidad, las tarifas o la geometría de las rutas. Esta información permite verificar de forma rápida el tamaño y la estructura del feed antes de integrarlo en el flujo de procesamiento del simulador.

La propia comunidad GTFS publica recomendaciones de calidad de publicación (persistencia de identificadores, estabilidad de URL de feed, cobertura temporal mínima y buenas prácticas de consistencia), que son relevantes para garantizar explotación automatizada en entornos de producción o experimentación [?]. Además, el validador canónico mantenido por MobilityData se ha convertido en herramienta estándar para control de calidad de feeds estáticos antes de su uso analítico [?]. En este trabajo, GTFS cumple una doble función: por un lado, alimentar la capa de consulta de la red de autobús urbano y, por otro, proporcionar los datos necesarios para construir el grafo multimodal empleado posteriormente por OpenTripPlanner.

2.3. Tecnologías abiertas de enrutado

Una vez descritas las fuentes de datos que permiten representar la red urbana y la oferta de transporte público, la segunda pieza fundamental de un simulador de movilidad es el algoritmo de enrutado. Estos motores permiten transformar la información geoespacial y temporal en itinerarios concretos, así como obtener variables de servicio relevantes, como el tiempo de viaje, la distancia recorrida, los transbordos o las fases de acceso y egreso. En este trabajo se emplean dos tecnologías abiertas con funciones complementarias: OSRM, orientado al cálculo eficiente de rutas sobre red viaria, y OpenTripPlanner, especializado en planificación multimodal con transporte público.

2.3.1. OSRM

OSRM (*Open Source Routing Machine*) es uno de los motores abiertos más utilizados para cálculo de rutas sobre red viaria OSM, especialmente cuando se necesitan tiempos de respuesta bajos y gran volumen de consultas [?, ?]. Su interés en un simulador de movilidad no está solo en obtener una ruta entre dos puntos, sino en poder generar de forma sistemática atributos de viaje (tiempo, distancia o matrices origen-destino) que después se integran en análisis y modelos predictivos.

La principal fortaleza técnica de OSRM es su enfoque de preprocesado: antes de servir consultas, el sistema transforma el extracto `.osm.pbf`, que es el formato binario comprimido habitualmente utilizado para distribuir datos de OpenStreetMap, en estructuras optimizadas de búsqueda. Este diseño desplaza coste al inicio, pero permite consultas rápidas y estables durante la fase de explotación. Además, OSRM trabaja con perfiles de movilidad diferenciados (por ejemplo, coche, bicicleta y a pie), lo que permite modelar de forma explícita costes de viaje distintos por modo. A nivel interno, OSRM se apoya en algoritmos de aceleración de rutas: MLD (*Multi-Level Dijkstra*), que divide la red en niveles para reducir el espacio de búsqueda en cada consulta, y CH (*Contraction Hierarchies*), que simplifica el grafo con atajos para acelerar rutas largas [?, ?].

2.3.2. OpenTripPlanner

OpenTripPlanner (OTP) es un planificador multimodal diseñado para combinar red de calle (OSM) y red de transporte público programado (GTFS) en un único problema de viaje puerta a puerta [?, ?]. Su función difiere de la de un motor de enrutado viario convencional, ya que no se limita a calcular el tramo sobre la red de calles, sino que también representa de manera integrada las fases de acceso peatonal, los tiempos de espera, el recorrido en transporte público, los posibles transbordos y el tramo final hasta el destino.

La documentación oficial de OTP describe una arquitectura basada en construcción previa de grafo y posterior explotación por API de planificación. Ese grafo integra simultáneamente geometría de red y programación temporal del servicio, por lo que la consulta de rutas depende de fecha y hora, no solo de coordenadas [?, ?]. Esta dimensión temporal es la base para representar transporte público de forma operativa.

En la salida, OTP devuelve itinerarios descompuestos en tramos o segmentos de viaje, denominados *legs* en su propia documentación, con información sobre el modo utilizado, los tiempos parciales, el número de transbordos y los metadatos de cada línea. Esta estructura resulta especialmente útil para el análisis multimodal, ya que permite distinguir con

precisión las distintas fases del desplazamiento. Por contraste, motores viarios como OSRM están orientados al cálculo rápido de rutas sobre red de calle y no incorporan de forma nativa la lógica propia del transporte público, con horarios, transbordos y secuencias diferenciadas dentro de un mismo itinerario.

2.4. Plataformas propietarias y servicios gestionados

Junto a las tecnologías abiertas de enrutado, el ecosistema actual de movilidad incluye también plataformas propietarias que ofrecen estos mismos servicios mediante API gestionadas. La relevancia industrial de este problema ha favorecido la aparición de soluciones comerciales muy maduras, orientadas tanto al desarrollo de producto como a la integración rápida en aplicaciones web y móviles. Aunque estas plataformas simplifican el despliegue técnico, también introducen condicionantes específicos en términos de coste, dependencia del proveedor y reproducibilidad.

2.4.1. Google Maps Platform

Google Maps Platform se ha convertido en un estándar de facto en los servicios comerciales de localización y navegación orientados al desarrollo de productos digitales. En particular, *Routes API* ofrece cálculo de rutas multimodo, metadatos de viaje y un ecosistema de integración especialmente maduro para aplicaciones web, móviles y, de forma destacada, entornos basados en Android [?].

Para proyectos de desarrollo de producto, este modelo reduce de forma notable la complejidad operativa, ya que no exige desplegar ni mantener infraestructura propia de enrutado y permite acceder a funcionalidades avanzadas mediante API. Esta característica ha favorecido su adopción en aplicaciones comerciales, especialmente en entornos móviles y ecosistemas integrados con servicios de Google. No obstante, en contextos de investigación aplicada o en escenarios con un volumen elevado de simulaciones, aparecen limitaciones relevantes: por un lado, el coste económico crece con el número de peticiones y con el tipo de servicio consumido; por otro, la ejecución queda condicionada por cuotas de uso, políticas del proveedor y disponibilidad externa de la plataforma [?]. Estas restricciones reducen su idoneidad cuando se busca trazabilidad completa, control experimental y escalabilidad económica predecible.

2.4.2. Otras plataformas de referencia

Además de Google Maps Platform, el ecosistema actual incluye otras alternativas consolidadas de consumo por API, entre ellas Mapbox [?] o TomTom [?]. Estas plataformas ofrecen catálogos amplios (rutas, matrices, navegación, tráfico y servicios avanzados según proveedor), y comparten una lógica común de uso gestionado mediante credenciales, límites de consumo y planes de servicio.

También existen servicios intermedios como openrouteservice, que proporcionan API pública y, al mismo tiempo, opciones de despliegue propio [?, ?]. Este tipo de solución puede ser útil como puente entre experimentación rápida y control de infraestructura, aunque con sus propias restricciones de uso en modalidad pública.

La Tabla 2.1 resume esta comparación y la decisión tecnológica adoptada en el proyecto. Para un simulador académico orientado a experimentación, trazabilidad y ejecución repetida de escenarios, la combinación OSRM + OTP en infraestructura propia ofrece un equilibrio más adecuado que una API comercial gestionada, aunque implique una mayor complejidad de despliegue.

Tabla 2.1: Comparación resumida de las soluciones de enrutado consideradas en este trabajo. Elaboración propia a partir de [?, ?, ?, ?].

Solución	Tipo de red	Coste de uso	Adecuación al TFM
OSRM	Red viaria OSM, perfiles por modo	Infraestructura propia	Muy adecuado para consultas masivas y control experimental
OTP	Red multimodal OSM + GTFS	Infraestructura propia	Muy adecuado para transporte público y análisis puerta a puerta
Google Maps Platform	API comercial multimodo gestionada	Pago por petición y cuotas	Útil como referencia industrial, menos adecuado para reproducibilidad

2.5. Modelado de elección modal

Una vez descrita la infraestructura tecnológica que permite representar la red y calcular itinerarios, es necesario incorporar una capa de modelado que permita analizar el comporta-

miento de los viajeros. En un simulador de movilidad, no basta con conocer qué alternativas existen para un desplazamiento determinado, sino que también es necesario estimar cuál de ellas es más probable que sea elegida en función de sus atributos de servicio y de las características del usuario. Esta cuestión se aborda habitualmente mediante modelos de elección discreta y, más recientemente, mediante técnicas de aprendizaje automático aplicadas a la predicción de la elección modal [?, ?].

En la literatura reciente, una de las referencias más utilizadas para este tipo de problemas es el dataset London Passenger Mode Choice (LPMC), construido a partir de viajes observados en Londres y enriquecido con variables de nivel de servicio para distintos modos de transporte [?, ?]. Su interés en este trabajo no está en el caso de estudio concreto, sino en que proporciona una base metodológica y experimental muy próxima al problema abordado en este TFM.

2.5.1. Modelos de utilidad aleatoria

Este problema se ha abordado tradicionalmente mediante los denominados modelos de utilidad aleatoria (*Random Utility Models*, RUM), ampliamente utilizados en transporte para analizar decisiones de elección discreta, como la elección del modo de transporte. En este enfoque, el decisor elige una alternativa dentro de un conjunto de opciones mutuamente excluyentes, por ejemplo caminar, usar la bicicleta, utilizar transporte público o desplazarse en coche [?, ?].

La idea central de estos modelos es que cada viajero asocia una utilidad a cada alternativa disponible dentro de su conjunto de elección, y se asume que elegirá aquella que le proporcione una mayor utilidad. Sin embargo, dicha utilidad no puede observarse de forma completa, ya que parte de los factores que influyen en la decisión sí pueden ser medidos por el analista, mientras que otros permanecen ocultos o no observados. Por ello, la utilidad de una alternativa suele descomponerse en un término determinista y un término aleatorio:

$$U_{in} = V_{in} + \varepsilon_{in} \quad (2.1)$$

donde U_{in} representa la utilidad total que el individuo n asocia a la alternativa i , V_{in} es la componente sistemática o determinista de dicha utilidad, y ε_{in} recoge los factores no observados que también influyen en la decisión.

Bajo este planteamiento, el viajero se considera racional en el sentido de que selecciona la alternativa que maximiza su utilidad. En consecuencia, la elección observada puede expresarse en términos probabilísticos como la probabilidad de que la utilidad de una alternativa

sea mayor o igual que la del resto de alternativas disponibles:

$$P_{in} = P(U_{in} \geq U_{jn} \forall j \in C) \quad (2.2)$$

donde C representa el conjunto de alternativas consideradas. De este modo, los RUM permiten traducir un problema de comportamiento individual en un modelo probabilístico de elección, capaz de relacionar atributos del viaje, características del individuo y probabilidad de seleccionar cada modo de transporte.

2.5.2. Modelo Logit Multinomial

Entre los modelos derivados del enfoque RUM, el más extendido en el análisis de elección modal es el Modelo Logit Multinomial (*Multinomial Logit*, MNL). Su popularidad se debe a que ofrece una formulación matemática sencilla, una interpretación clara de los parámetros y una estimación relativamente eficiente desde el punto de vista computacional. En el contexto del transporte, el MNL ha sido utilizado de forma recurrente para estudiar cómo variables como el tiempo de viaje, el coste, los transbordos o determinadas características sociodemográficas influyen en la probabilidad de elegir un modo de transporte frente a otro [?].

El modelo MNL se obtiene al asumir que el término aleatorio de la utilidad sigue una distribución Gumbel independiente e idénticamente distribuida para todas las alternativas. Bajo esta hipótesis, la probabilidad de que el individuo n elija la alternativa i puede expresarse de la siguiente forma:

$$P_{in} = \frac{\exp(V_{in})}{\sum_{j=1}^I \exp(V_{jn})} \quad (2.3)$$

donde I es el número total de alternativas disponibles y V_{in} representa la utilidad sistemática de la alternativa i para el individuo n . Esta expresión da lugar a una función de probabilidad de tipo sigmoideal, de manera que pequeñas variaciones en la utilidad representativa tienen mayor efecto cuando la probabilidad de elección se encuentra en valores intermedios que cuando una alternativa ya es claramente dominante o claramente poco atractiva. Esta propiedad resulta especialmente útil para interpretar cambios marginales en los atributos del servicio, por ejemplo ante mejoras en tiempo o coste de una determinada alternativa.

La Figura 2.1 ilustra de forma esquemática esta forma sigmoideal de la probabilidad de elección en el modelo MNL.

En la práctica, la componente determinista de la utilidad suele especificarse como una




Figura 2.1: Forma sigmoide ilustrativa de la probabilidad de elección en el modelo MNL. Elaboración propia.

combinación lineal de atributos observables:

$$V_{in} = \beta_{i0} + \sum_k \beta_{ik} x_{ink} \quad (2.4)$$

donde x_{ink} representa el valor del atributo k asociado a la alternativa i para el individuo n , β_{ik} es el parámetro que mide la influencia de dicho atributo y β_{i0} es una constante específica de la alternativa. Esta formulación permite cuantificar el efecto relativo de variables como el tiempo de viaje, el coste monetario, el número de transbordos o el acceso peatonal, entre otras. En términos interpretativos, los parámetros estimados indican cómo varía la utilidad de cada modo cuando cambian sus atributos observables.

La estimación de los parámetros del modelo se realiza habitualmente mediante máxima verosimilitud. Para ello, se define una función de verosimilitud que mide la probabilidad de observar las elecciones registradas en la muestra dadas unas determinadas estimaciones de los parámetros. El objetivo del proceso de ajuste consiste en encontrar los valores de β que maximizan dicha verosimilitud, o de forma equivalente, que maximizan la log-verosimilitud del modelo. Este procedimiento constituye la base clásica de estimación de modelos de elección discreta y permite obtener un modelo interpretable y coherente con la teoría del comportamiento del viajero.

En este TFM, el modelo MNL resulta relevante como referencia metodológica, ya que proporciona una base teórica sólida para representar la elección modal a partir de atributos del desplazamiento. Además, sirve como punto de comparación frente a enfoques más flexibles basados en aprendizaje automático, que se describen en los apartados siguientes.

Una limitación conocida del modelo MNL es la hipótesis de independencia de alternati-

vas irrelevantes (*Independence of Irrelevant Alternatives*, IIA), derivada de la suposición de errores independientes e idénticamente distribuidos. Esta propiedad implica que la relación de sustitución entre dos alternativas no depende de la presencia o de las características del resto de modos, lo cual puede resultar restrictivo en problemas de movilidad donde algunas opciones están más correlacionadas entre sí que otras [?, ?]. Aun así, el MNL sigue siendo el punto de partida más habitual en la literatura por su equilibrio entre simplicidad, interpretabilidad y capacidad descriptiva.

2.5.3. Limitaciones del enfoque clásico

A pesar de su amplia utilización en el análisis de elección modal, los modelos basados en utilidad aleatoria presentan ciertas limitaciones cuando se aplican a problemas complejos de movilidad. En primer lugar, requieren especificar de forma explícita la forma funcional de la utilidad sistemática, lo que implica que el analista debe decidir previamente qué variables incluir y cómo se relacionan con la utilidad de cada alternativa. En muchos casos, esta especificación se realiza mediante combinaciones lineales de atributos del viaje, lo que puede resultar restrictivo cuando las relaciones reales entre variables son no lineales o presentan interacciones complejas [?, p. 20].

Otra limitación relevante es que los modelos clásicos suelen asumir estructuras relativamente simples en la distribución de los términos de error. En el caso del modelo Logit Multinomial, por ejemplo, la hipótesis de independencia de alternativas irrelevantes puede no reflejar adecuadamente situaciones en las que algunas alternativas presentan correlaciones más fuertes entre sí, como ocurre frecuentemente entre distintos modos de transporte público o entre modos motorizados.

Además, desde un punto de vista práctico, la especificación de modelos econométricos puede requerir un proceso iterativo de selección de variables, transformación de atributos y validación de supuestos teóricos. Aunque este enfoque proporciona modelos interpretables y coherentes con la teoría del comportamiento del viajero, puede resultar menos flexible cuando se trabaja con conjuntos de datos de alta dimensionalidad o con relaciones complejas entre variables.

2.5.4. Aprendizaje automático para elección modal

Con el aumento de la disponibilidad de datos y de la capacidad computacional, en los últimos años han ganado relevancia los enfoques basados en aprendizaje automático para el análisis de elección modal. Desde esta perspectiva, la elección de modo puede formularse

también como un problema de clasificación supervisada, en el que el objetivo consiste en predecir la alternativa elegida a partir de un conjunto de variables explicativas relacionadas con el viaje y con las características del individuo.

A diferencia de los modelos clásicos de elección discreta, muchos algoritmos de aprendizaje automático no requieren especificar de forma explícita la forma funcional de la relación entre variables. En su lugar, aprenden patrones directamente a partir de los datos de entrenamiento, lo que les permite capturar relaciones no lineales, interacciones complejas entre atributos y estructuras de decisión difíciles de representar mediante modelos lineales tradicionales.

Entre las técnicas más utilizadas en este contexto destacan los métodos basados en árboles de decisión y los modelos de conjunto (*ensemble models*) derivados de ellos, como Random Forest o Gradient Boosting Decision Trees, así como los modelos basados en redes neuronales profundas. Estos enfoques han mostrado un rendimiento predictivo competitivo en numerosos problemas de clasificación tabular, incluyendo aplicaciones en transporte y elección modal.

En este trabajo se adopta esta perspectiva complementaria: el modelo Logit Multinomial se considera como referencia metodológica clásica, mientras que distintos modelos de aprendizaje automático se utilizan para explorar alternativas con mayor capacidad predictiva. En particular, la arquitectura del simulador se ha diseñado para permitir la integración de diferentes modelos de clasificación, entre ellos Random Forest, Gradient Boosting Decision Trees y redes neuronales profundas, de forma que puedan compararse sus resultados en el contexto del problema de elección modal analizado. Esta comparación resulta coherente con la evidencia reciente disponible para datasets reales de elección modal, entre ellos LPMC [?].

2.5.5. Random Forests

Random Forest es un método de aprendizaje automático basado en la combinación de múltiples árboles de decisión entrenados sobre subconjuntos distintos de los datos. El modelo fue propuesto por Breiman [?] como una extensión de los árboles de clasificación tradicionales, con el objetivo de mejorar su estabilidad y capacidad predictiva. En diversas revisiones de la literatura, este tipo de modelos aparece además como una de las familias más utilizadas en comparativas recientes de elección modal.

La idea fundamental consiste en entrenar un gran número de árboles de decisión sobre diferentes subconjuntos de los datos de entrenamiento. Cada árbol se construye utilizando una muestra aleatoria del conjunto de datos original (técnica conocida como *bootstrap*

sampling) y, además, en cada división del árbol se considera únicamente un subconjunto aleatorio de variables explicativas. Este doble proceso de aleatorización permite reducir la correlación entre árboles individuales y, en consecuencia, mejorar el rendimiento del modelo agregado.

En problemas de clasificación, como el de elección modal, cada árbol produce una predicción independiente y la decisión final se obtiene mediante votación mayoritaria entre todos los árboles del bosque. Este mecanismo permite capturar relaciones no lineales entre variables y manejar de forma robusta conjuntos de datos con múltiples atributos.

En el ámbito del transporte, los modelos Random Forest se han utilizado en distintos trabajos para predecir la elección de modo de transporte, ya que ofrecen un buen equilibrio entre capacidad predictiva, robustez frente al sobreajuste y relativa facilidad de interpretación mediante medidas de importancia de variables. No obstante, la evidencia comparativa reciente sugiere que su rendimiento puede quedar por debajo del de otros métodos más potentes de boosting en algunos conjuntos de datos reales [?].

2.5.6. Gradient Boosting Decision Trees

Los modelos basados en *Gradient Boosting Decision Trees* (GBDT) constituyen otra familia de métodos de aprendizaje automático ampliamente utilizados en problemas de clasificación con datos tabulares. A diferencia de los métodos basados en bagging, como Random Forest, el enfoque de boosting construye los árboles de decisión de forma secuencial, de modo que cada nuevo árbol intenta corregir los errores cometidos por el conjunto de árboles anteriores [?].

El proceso comienza entrenando un primer árbol de decisión sencillo sobre los datos de entrenamiento. A continuación, se construyen árboles adicionales que se ajustan sobre los residuos o errores del modelo previo. De este modo, el modelo final se obtiene como la suma ponderada de múltiples árboles débiles, cada uno de los cuales contribuye a mejorar gradualmente la predicción global.

Entre las implementaciones más conocidas de este enfoque se encuentra XGBoost (*Extreme Gradient Boosting*), una biblioteca optimizada que introduce mejoras en eficiencia computacional, regularización del modelo y manejo de grandes conjuntos de datos [?]. Gracias a estas características, XGBoost se ha convertido en una de las técnicas más utilizadas en problemas de aprendizaje supervisado con datos estructurados y ha mostrado un comportamiento especialmente competitivo en comparativas recientes de elección modal.

En el contexto de este TFM, los modelos basados en Gradient Boosting resultan especialmente relevantes, ya que permiten capturar relaciones no lineales entre los atributos

del viaje y la elección modal. Además, su buen rendimiento predictivo y su flexibilidad para manejar distintos tipos de variables los convierten en una herramienta adecuada para integrarse en el simulador de movilidad desarrollado en este trabajo.

2.5.7. Redes Neuronales Profundas

Las redes neuronales profundas (*Deep Neural Networks*, DNN) constituyen otra familia de modelos de aprendizaje automático que ha experimentado un crecimiento significativo en los últimos años. Estas técnicas se basan en arquitecturas formadas por múltiples capas de neuronas artificiales que transforman progresivamente las variables de entrada mediante combinaciones lineales y funciones de activación no lineales [?].

A diferencia de los modelos basados en árboles, las redes neuronales permiten aprender representaciones internas de los datos a través de varias capas ocultas, lo que facilita capturar relaciones complejas entre variables. Esta capacidad de modelar interacciones no lineales ha motivado su aplicación en numerosos problemas de predicción y clasificación, incluyendo el análisis del comportamiento de los viajeros.

En problemas de elección modal, las redes neuronales profundas pueden utilizarse para estimar la probabilidad de seleccionar cada modo de transporte a partir de atributos del desplazamiento y características sociodemográficas del usuario. Aunque estos modelos suelen requerir mayor volumen de datos y un proceso de ajuste más cuidadoso que los métodos basados en árboles, también ofrecen una elevada flexibilidad para capturar patrones complejos presentes en los datos.

Los tres enfoques descritos en esta sección (Random Forest, Gradient Boosting y redes neuronales profundas) se evalúan de forma comparativa sobre el dataset LPMC. Su entrenamiento, ajuste e integración en el simulador de movilidad se detallan en el capítulo 5.

3. Metodología

Este capítulo recoge la gestión del proyecto con un enfoque SCRUM adaptado a un TFM individual. Se busca dejar trazabilidad clara de qué se planificó, qué se ejecutó, qué bloqueos aparecieron y qué decisiones técnicas se tomaron en cada iteración.

3.1. SCRUM adaptado a un desarrollo unipersonal

SCRUM es una metodología ágil de carácter iterativo e incremental, orientada a organizar el trabajo en ciclos cortos, priorizar entregas de valor y revisar de forma continua el avance del producto [?]. Aunque su formulación original está pensada para equipos, sus principios también pueden adaptarse a proyectos individuales cuando se busca mantener planificación, trazabilidad y capacidad de reacción ante cambios.

En este trabajo se ha utilizado una adaptación práctica de SCRUM, no como aplicación estricta del marco en todos sus elementos formales, sino como guía para estructurar el desarrollo del simulador, registrar decisiones y ordenar la evolución del proyecto. Esta adaptación ha resultado útil por tres motivos. En primer lugar, porque se han combinado tareas heterogéneas, incluyendo desarrollo backend, frontend, integración de motores de enrutado, tratamiento de datos, entrenamiento de modelos y redacción de memoria. En segundo lugar, porque el alcance real del proyecto ha ido evolucionando a medida que se validaban soluciones técnicas y se detectaban bloqueos. Por último, porque el seguimiento periódico con el tutor ha funcionado como mecanismo natural de revisión y reorientación.

Desde el punto de vista organizativo, la Guía Scrum 2020 define un *Scrum Team* compuesto por tres responsabilidades principales: *Product Owner*, *Scrum Master* y *Developers* [?]. En un trabajo unipersonal esta separación no puede reproducirse de forma literal, por lo que se ha reinterpretado del siguiente modo:

-
- **Product Owner:** el tutor académico ha asumido de forma aproximada esta función, al validar prioridades, orientar el alcance funcional del prototipo y revisar la utilidad de los entregables desde el punto de vista del objetivo del TFM.
 - **Scrum Master:** esta responsabilidad ha sido asumida por el propio autor del trabajo, en la medida en que ha organizado iteraciones, registrado bloqueos, mantenido la trazabilidad del progreso y ajustado la planificación cuando han surgido incidencias técnicas o cambios de enfoque.
 - **Developers:** el desarrollo técnico también ha recaído íntegramente en el autor, responsable de la implementación del simulador, la integración de servicios, el entrenamiento de modelos y la documentación de resultados.


En consecuencia, varias responsabilidades propias de un equipo Scrum han quedado concentradas en una única persona, mientras que el tutor ha actuado como agente externo de supervisión, validación y priorización. Esta circunstancia introduce diferencias claras respecto a un SCRUM de equipo, pero no invalida su uso como marco ligero de gestión. En este contexto, lo más relevante no ha sido reproducir todas las ceremonias de forma estricta, sino conservar los elementos que aportan valor real al proyecto: backlog priorizado, trabajo por iteraciones, revisión periódica y registro explícito de decisiones.

La metodología seguida en este trabajo se ha apoyado en los siguientes principios:

- dividir el trabajo en sprints con objetivos acotados y entregables identificables;
- mantener un *Product Backlog* vivo, revisado conforme avanzaba el proyecto;
- registrar en cada iteración qué se planificó, qué se completó y qué problemas aparecieron;
- utilizar las reuniones con el tutor como mecanismo de revisión y re-priorización;
- orientar cada sprint a la obtención de un incremento funcional o documental del proyecto.

En cuanto al seguimiento, las reuniones con el tutor comenzaron a finales de 2025, aproximadamente entre octubre y noviembre, con una periodicidad quincenal, normalmente los martes. Una vez finalizado el primer cuatrimestre y superada la carga principal de exámenes, la cadencia pasó a ser semanal a partir de febrero y marzo de 2026, con el objetivo de acelerar el ritmo de desarrollo y acotar con mayor precisión el trabajo asociado a cada sprint. Este cambio de frecuencia reforzó el carácter iterativo del proyecto y facilitó una validación más cercana del backlog y de los entregables.

La Figura 3.1 resume visualmente este ciclo de trabajo adaptado a un desarrollo unipersonal, mostrando la relación entre backlog, planificación, ejecución y revisión periódica con el tutor.



SCRUM adaptado a desarrollo unipersonal

Figura 3.1: Esquema del ciclo de trabajo SCRUM adaptado al desarrollo unipersonal del proyecto. Elaboración propia.

Esta metodología ha encajado bien con la naturaleza del proyecto. Por una parte, ha permitido avanzar de manera incremental desde un prototipo inicial de rutas hasta un MVP funcional con integración de OSRM, OTP, GTFS y un modelo de elección modal. Por otra, ha facilitado documentar de forma ordenada tanto el trabajo ya completado como las líneas de evolución previstas, incluyendo mejoras visuales, ampliación de modelos y posibles análisis adicionales de simulación. A partir de este marco general, en los apartados siguientes se presenta el backlog del proyecto y el histórico de sprints ejecutados.

3.2. Product Backlog

3.2.1. Backlog inicial

El *Product Backlog* se definió como una lista viva de trabajo, organizada en grandes bloques funcionales y técnicos. En lugar de partir de un conjunto cerrado de tareas detalladas desde el inicio, se optó por un backlog de alto nivel que pudiera refinarse a medida que se validaban decisiones de diseño y se consolidaba el MVP del simulador.

En una primera aproximación, los elementos principales del backlog fueron los siguientes:

1. Definir una arquitectura base cliente-servidor para desacoplar frontend, backend y servicios externos.
2. Construir un prototipo web funcional con mapa interactivo, selección de origen-destino y visualización de rutas.
3. Integrar OSRM en local con perfiles diferenciados para coche, bicicleta y desplazamiento a pie.
4. Incorporar transporte público urbano mediante GTFS de Toledo y OpenTripPlanner.
5. Diseñar una API propia que unifique consultas de rutas, exploración GTFS e inferencia modal.
6. Preparar una pipeline reproducible de datos para el dataset LPMC.
7. Entrenar y validar un primer modelo de elección modal utilizable dentro del simulador.
8. Integrar el modelo de inferencia en backend y frontend de forma modular.
9. Mejorar la interfaz, la experiencia de usuario y la capacidad de análisis visual del sistema.
10. Documentar la solución, registrar la evolución del proyecto y redactar la memoria final.

Conforme avanzó el trabajo, este backlog se fue refinando en tareas más concretas. Algunos elementos inicialmente planteados como trabajo futuro pasaron a formar parte del desarrollo principal, mientras que otros quedaron aplazados para iteraciones posteriores. A fecha de redacción de esta memoria, la parte nuclear del simulador puede considerarse ya implementada, por lo que el backlog actual se concentra principalmente en consolidación documental, mejoras visuales y ampliaciones funcionales sobre una base ya operativa.

Para facilitar su seguimiento, los elementos del backlog se agruparon en cuatro bloques:

- **Bloque funcional:** interfaz web, selección de viajes, cálculo de rutas, visualización de resultados y cuadro de información.
- **Bloque de integración de servicios:** despliegue y conexión de OSRM, OTP y GTFS dentro de una arquitectura reproducible.
- **Bloque de inteligencia artificial:** preprocesado del dataset LPMC, entrenamiento de modelos, validación e integración de inferencia.
- **Bloque documental y de cierre:** trazabilidad del proyecto, redacción de memoria, mejora de la presentación y preparación de resultados.

3.2.2. Priorización de items

La priorización del backlog no se realizó únicamente por orden técnico de implementación, sino por valor aportado al objetivo general del proyecto. En consecuencia, se siguió el siguiente criterio:

- **Prioridad alta:** elementos necesarios para disponer de un simulador funcional extremo a extremo, incluyendo mapa interactivo, rutas por modo, integración de transporte público y una primera versión operativa de la inferencia modal.
- **Prioridad media:** mejoras que aumentan la usabilidad, la claridad visual o la trazabilidad del sistema, pero que no bloquean el funcionamiento básico del MVP.
- **Prioridad evolutiva:** ampliaciones previstas una vez estabilizado el núcleo del sistema, como el entrenamiento de modelos adicionales, la mejora de análisis de escenarios o la incorporación de nuevas visualizaciones y métricas.

Este criterio explica el orden seguido durante el desarrollo. Primero se priorizó la infraestructura mínima para obtener rutas y visualizar resultados reales sobre el mapa; después se incorporó el bloque de modelado e inferencia; y finalmente se abordaron tareas de consolidación, mejora y documentación. De esta forma, cada sprint pudo orientarse a producir incrementos útiles sobre una base ya validada, en lugar de avanzar en paralelo sobre demasiados frentes abiertos.

3.3. Histórico de sprints ejecutados

En este apartado se resume la secuencia principal de trabajo seguida durante el desarrollo del proyecto. Dado que el TFM no arrancó con una planificación completamente cerrada

y que parte de la trazabilidad se ha reconstruido a partir de versiones funcionales, reuniones de seguimiento y artefactos generados, los periodos y esfuerzos indicados deben interpretarse como estimaciones razonables. Aun así, este histórico permite mostrar con claridad cómo evolucionó el proyecto desde la validación inicial de tecnologías hasta la integración final del simulador.

La Figura 3.2 muestra un diagrama de Gantt simplificado de los sprints ejecutados durante el desarrollo del proyecto. El diagrama refleja tanto la secuencia principal del desarrollo como la existencia de trabajo en paralelo, especialmente entre las fases de modelado y diseño web y en la redacción de la memoria.




Figura 3.2: Cronograma aproximado de los sprints ejecutados durante el desarrollo del TFM, representado como diagrama de Gantt simplificado. Elaboración propia.

3.3.1. Sprint 1: Validación inicial de OSRM mediante servicios remotos

Fechas: del 2 al 5 de diciembre de 2025.

Esfuerzo estimado: 8–12 horas.

Este sprint tuvo como objetivo investigar distintas herramientas de enrutado y, en particular, validar la viabilidad de OSRM dentro del proyecto mediante llamadas remotas desde una primera arquitectura cliente-servidor. El propósito no era todavía disponer de una so-

lución definitiva, sino comprobar que el flujo completo entre mapa, backend y cálculo de rutas resultaba técnicamente factible.

El principal resultado de esta iteración fue la construcción de un primer prototipo funcional y la identificación temprana de las limitaciones de los servicios remotos utilizados para las pruebas iniciales. Esta validación permitió confirmar el interés de OSRM como base del simulador, pero también puso de manifiesto la necesidad de avanzar hacia una infraestructura propia para garantizar comparabilidad real entre modos y mayor control experimental.

3.3.2. Sprint 2: Despliegue del servicio OSRM local multi-perfil

Fechas: del 6 al 11 de diciembre de 2025.

Esfuerzo estimado: 12–16 horas.

Una vez validado el uso de OSRM para este trabajo, este sprint se orientó al despliegue de una instancia local que permitiera obtener rutas diferenciadas para distintos modos de desplazamiento y, al mismo tiempo, mantener un control total sobre la infraestructura. Este cambio era necesario para asegurar reproducibilidad, trazabilidad y estabilidad en las comparaciones realizadas por el simulador.

Como resultado, el proyecto dejó de depender de servicios públicos externos y pasó a apoyarse en una base de cálculo local sobre la que posteriormente se construirían tanto la comparación modal como la integración con el resto de componentes del sistema.

3.3.3. Sprint 3: Incorporación del GTFS urbano de Toledo

Fechas: del 12 al 18 de diciembre de 2025.

Esfuerzo estimado: 10–14 horas.

El objetivo de esta iteración fue incorporar la red de transporte público urbano de Toledo al simulador a partir del feed GTFS descargado desde el Punto de Acceso Nacional (NAP) del Ministerio de Transportes. Para ello se desarrolló el módulo de lectura `gtfs_loader.py`, que parsea y mantiene en memoria la información de paradas, rutas, viajes y horarios, y se implementaron cuatro endpoints en el router `/api/gtfs`: listado de paradas con filtro opcional por bounding box, listado de líneas de la red, detalle de ruta con paradas ordenadas y trazado geométrico, y resumen de horarios por fecha.

En la capa de visualización se añadieron las paradas como marcadores circulares en el mapa con popup interactivo, desde el que el usuario puede consultar qué líneas dan servicio en cada parada. Este sprint no incluyó planificación de itinerarios, que se abordó en el sprint siguiente. Su resultado principal fue disponer de una representación operativa completa de

la red de bus urbano de Toledo, desacoplada del grafo OTP, lo que permite consultar la red aunque el planificador no esté disponible.

3.3.4. Sprint 4: Integración de OpenTripPlanner para rutas multimodales

Fechas: del 19 de diciembre de 2025 al 12 de febrero de 2026.

Esfuerzo estimado: 16–24 horas.

Tras la incorporación del GTFS, este sprint se centró en habilitar el cálculo de rutas de transporte público puerta a puerta mediante OpenTripPlanner. El objetivo era pasar de una visualización estática de red a una capacidad real de planificación multimodal, incorporando la combinación entre red peatonal y servicio de autobús urbano.

Esta fase supuso un salto cualitativo dentro del proyecto, ya que permitió integrar en una misma aplicación los modos viarios y el modo tránsito, haciendo posible una comparación más completa entre alternativas de viaje en el contexto urbano de Toledo.

3.3.5. Sprint 5: Diseño de la interfaz web y codificación visual por modo

Fechas: del 20 de diciembre de 2025 al 20 de febrero de 2026.

Esfuerzo estimado: 8–12 horas.

Este sprint se orientó a consolidar la experiencia de usuario y la legibilidad comparada de resultados. Las principales decisiones de diseño adoptadas fueron: codificación visual de rutas por modo (azul sólido para conducción, verde sólido para bicicleta y gris discontinuo para desplazamiento a pie); visualización de segmentos OTP diferenciada entre tramos en vehículo, representados en naranja, y tramos a pie, con la misma trama discontinua que el modo peatonal; cuatro basemaps seleccionables por el usuario (carto-light, OpenStreet-Map estándar, OpenTopoMap y satélite Esri); y marcadores SVG personalizados para origen y destino con iconografía diferenciada.

Se consolidó también el uso de TanStack Query para las peticiones al backend, que proporciona caché de respuestas, gestión declarativa de estados de carga y reintento automático en caso de error. Los segmentos de transporte público se restringieron a modo *transit*, evitando solapamientos visuales con las rutas viarias. El resultado fue una interfaz directamente utilizable como herramienta de análisis, no solo como demostración técnica del sistema de enrutado.

3.3.6. Sprint 6: Diseño de un modelo de clasificación de modo de viaje y procesamiento de datos

Fechas: del 21 de diciembre de 2025 al 17 de enero de 2026.

Esfuerzo estimado: 12–18 horas.

Este sprint tuvo como finalidad preparar la base metodológica del módulo de inteligencia artificial del proyecto. Para ello se abordó el estudio del dataset LPMC, la revisión de trabajos de referencia y el diseño del proceso de preparación de datos necesario para entrenar modelos de clasificación de modo de viaje con un criterio reproducible.

El trabajo realizado en esta fase no se orientó todavía a la integración en el simulador, sino a establecer una base sólida de modelado sobre la que poder entrenar, comparar y validar distintos enfoques en iteraciones posteriores.

3.3.7. Sprint 7: Entrenamiento y validación de los modelos de clasificación

Fechas: del 18 de enero al 21 de febrero de 2026.

Esfuerzo estimado: 14–20 horas.

Una vez definida la base de datos y el proceso de preparación, este sprint se centró en entrenar y validar los primeros modelos de clasificación de modo de viaje. El objetivo fue disponer de una referencia cuantitativa útil, suficientemente estable como para servir de punto de partida a la integración del módulo de inferencia dentro del simulador.

Como resultado, el proyecto avanzó desde una fase exploratoria sobre datos hacia una fase claramente aplicada, en la que ya era posible valorar el rendimiento de los modelos y decidir cuáles podían incorporarse al sistema de forma operativa.

3.3.8. Sprint 8: Escritura de la memoria y consolidación metodológica

Fechas: del 27 de enero al 24 de marzo de 2026, en paralelo a varios sprints técnicos.

Esfuerzo estimado: 10–14 horas en su arranque, ampliado de forma continua durante la redacción final.

La escritura de la memoria no se desarrolló como una actividad aislada al final del proyecto, sino como una línea de trabajo paralela que fue ganando peso a medida que el simulador y el bloque de modelado alcanzaban mayor madurez. El objetivo de este sprint fue consolidar la estructura documental del TFM, fijar el enfoque metodológico y dejar trazabilidad suficiente de las decisiones adoptadas a lo largo del desarrollo.

Su carácter transversal hace que este sprint deba interpretarse como una actividad de

acompañamiento al resto del proyecto. En la práctica, sirvió para ordenar el material generado, depurar la narrativa técnica y conectar la evolución funcional del sistema con la justificación académica del trabajo.

3.3.9. Sprint 9: Integración del módulo de inferencia en el simulador

Fechas: del 22 de febrero al 8 de marzo de 2026.

Esfuerzo estimado: 14–20 horas.

El objetivo de esta iteración fue integrar el módulo de inferencia modal dentro del simulador ya construido, conectando el bloque de modelado con la aplicación web y con la lógica general del backend. Con ello se buscaba que el sistema dejara de ser únicamente un comparador de rutas para incorporar también una capa predictiva sobre la elección de modo de viaje.

Esta integración representó la convergencia de las dos grandes líneas del TFM: por un lado, la construcción del simulador de movilidad urbana; por otro, el diseño y validación de modelos de clasificación. A partir de este punto, el proyecto quedó configurado como una aplicación final capaz de combinar cálculo de rutas, visualización cartográfica e inferencia modal en un mismo entorno de trabajo.

3.4. Cierre del ciclo de desarrollo

La secuencia de sprints descrita en este capítulo llevó el proyecto desde una primera validación de tecnologías de enrutado hasta un simulador funcional extremo a extremo, con integración de rutas viarias, transporte público multimodal y predicción de elección modal mediante aprendizaje automático. Cada iteración aportó un incremento concreto sobre la base anterior: el prototipo inicial de rutas se amplió con un servicio local multiperfil, se integró la red de transporte público de Toledo, se incorporó la planificación multimodal con OTP, se consolidó la interfaz y, finalmente, se conectó el módulo de inferencia con el resto del sistema.

La arquitectura resultante y las decisiones técnicas adoptadas a lo largo de este proceso se describen en el capítulo 4. Los detalles de implementación de cada componente se recogen en el capítulo 5.

4. Arquitectura del sistema

Este capítulo describe la organización estructural del simulador: los componentes que lo forman, cómo se relacionan entre sí y las decisiones de diseño que condicionan esa organización. El detalle de implementación de cada componente se desarrolla en el capítulo 5.

El sistema está compuesto por cinco bloques funcionales: una interfaz web, un backend de orquestación, tres instancias del motor de enrutado viario OSRM, un planificador de transporte público basado en OpenTripPlanner y un módulo de inferencia de elección modal. Todos ellos se despliegan como contenedores Docker orquestados mediante Docker Compose.

4.1. Visión general

La Figura 4.1 muestra la arquitectura de alto nivel del sistema. El principio de diseño central es que el frontend nunca se comunica directamente con ningún servicio externo: toda petición pasa por el backend de FastAPI, que actúa como única puerta de entrada y punto de orquestación. Esta decisión simplifica el control de versiones de la API, centraliza el manejo de errores y evita exponer los puertos internos de OSRM y OTP al navegador.

El frontend expone la interfaz cartográfica al usuario y delega en el backend el cálculo de rutas, la consulta de horarios GTFS y la inferencia modal. El backend integra cuatro routers diferenciados: `/api/osrm` para rutas viarias por perfil, `/api/otp` para itinerarios multimodales, `/api/gtfs` para información estática de la red de transporte, y `/api/lpmc` para la inferencia de elección modal. Cada router encapsula la lógica de comunicación con su servicio subyacente y expone al frontend una interfaz homogénea independiente de los detalles de cada protocolo.

Arquitectura del Simulador de Movilidad Urbana




Figura 4.1: Arquitectura general del simulador de movilidad urbana.

4.2. Infraestructura y orquestación

La infraestructura del sistema se define íntegramente en un fichero `docker-compose.yml` en la raíz del repositorio. El despliegue completo se obtiene con un único comando (`docker compose up --build`), lo que elimina dependencias de entorno en la máquina anfitriona y garantiza reproducibilidad.

La Tabla 4.1 resume los servicios definidos, sus puertos y su función en el sistema.

Tabla 4.1: Servicios Docker Compose del simulador.

Servicio	Puerto	Función
frontend	5173	Interfaz web React servida por Vite.
backend	8000	API FastAPI, orquestación y lógica de negocio.
osrm-car	5000	Motor OSRM con perfil de vehículo a motor.
osrm-bike	5001	Motor OSRM con perfil de bicicleta.
osrm-foot	5002	Motor OSRM con perfil peatonal.
otp	8080	OpenTripPlanner 2.x con grafo multimodal de Toledo.

Los servicios OSRM montan los grafos viarios preprocesados desde directorios locales mediante volúmenes Docker. OpenTripPlanner carga el grafo multimodal (`graph.obj`) generado a partir de los datos OSM de Castilla-La Mancha y el feed GTFS urbano de Toledo. Estos artefactos pesados no se versionan en el repositorio Git y deben generarse o descargarse antes del primer despliegue, según se describe en el anexo ??.

La razón por la que OSRM se instancia tres veces en lugar de usar un único servidor multiperfil es que la imagen oficial de OSRM no admite perfiles simultáneos: cada proceso solo puede servir el grafo con el que fue preprocesado. Esta limitación fue el detonante del cambio de la solución inicial basada en el servidor de demostración público, que únicamente ofrecía perfil de conducción, a la infraestructura local multiperfil descrita aquí.

4.3. Backend: capa de orquestación

El backend está implementado con FastAPI sobre Python y se organiza en cuatro routers, cada uno responsable de un dominio funcional. La separación en routers permite desarrollar, probar y documentar cada integración de forma independiente. La Tabla 4.2 recoge los endpoints principales expuestos por cada router.

Tabla 4.2: Endpoints principales de la API REST del backend.

Método	Ruta	Descripción
POST	<code>/api/osrm/routes</code>	Rutas viarias multimodales (OSRM).
POST	<code>/api/otp/routes</code>	Itinerario de transporte público (OTP).
GET	<code>/api/gtfs/stops</code>	Listado de paradas con filtro bbox.
GET	<code>/api/gtfs/routes</code>	Listado de líneas de la red.
GET	<code>/api/gtfs/routes/{id}</code>	Detalle de ruta: paradas y trazado.
GET	<code>/api/gtfs/routes/{id}/schedule</code>	Horarios de una línea por fecha.
POST	<code>/api/lpmc/predict</code>	Inferencia de elección modal.
POST	<code>/api/lpmc/debug-features</code>	Vector de características antes/después del escalado.
GET	<code>/health</code>	Comprobación de disponibilidad.

El router `/api/osrm` recibe un par origen-destino con la lista de perfiles solicitados, consulta en paralelo las instancias OSRM correspondientes y devuelve al frontend las rutas con distancia, duración y geometría decodificada para su representación cartográfica.

El router `/api/otp` consulta el planificador multimodal y gestiona la paginación de itinerarios alternativos. La respuesta incluye el desglose por tramos (*legs*), con tipo de modo,

geometría, parada de inicio y fin, y agencia operadora cuando el tramo es de transporte público. Los itinerarios se ordenan por duración y se selecciona automáticamente el primero que incluya al menos un tramo de transporte público; si ninguno lo incluye, se devuelve el de menor duración.

El router `/api/gtfs` expone información estática de la red de transporte: listado de paradas con sus líneas asociadas, listado de rutas, detalle de ruta con paradas ordenadas y trazado geométrico, y resumen de horarios por fecha. Estos datos se leen directamente del feed GTFS descomprimido en el backend, sin depender de OpenTripPlanner, lo que permite consultar la red aunque el grafo OTP no esté disponible.

El router `/api/lpmc` recibe las coordenadas de origen y destino junto con el perfil socio-demográfico del viajero, construye el vector de variables de entrada al modelo consultando OSRM y OTP internamente, aplica el escalado parcial, ejecuta la inferencia con el modelo seleccionado y devuelve las probabilidades por modo. El endpoint `/debug-features` expone el vector de características antes y después del escalado, facilitando la validación del pipeline de inferencia.

4.4. Frontend: interfaz cartográfica

El frontend está desarrollado con React, Vite y TypeScript. La aplicación se estructura en dos componentes principales: `App`, que concentra el estado global y la lógica de negocio del cliente, y `MapView`, que encapsula la representación cartográfica mediante React-Leaflet.

`App` gestiona los puntos de origen y destino, el modo de transporte activo, los resultados de rutas, la capa GTFS y el perfil de usuario para la inferencia. Las peticiones al backend se realizan con TanStack Query (`useQuery` y `useMutation`), que proporciona caché, gestión de estados de carga y reintento automático. El estado local de React es suficiente para el alcance del prototipo: no existe flujo de datos compartido entre componentes independientes que justifique una biblioteca adicional de gestión de estado.

`MapView` recibe el estado relevante como *props* y se encarga exclusivamente de la renderización cartográfica: marcadores de origen y destino, polilíneas de ruta coloreadas según el modo activo, paradas GTFS con popups interactivos y segmentos OTP diferenciados visualmente entre tramos a pie y tramos en vehículo. Los segmentos de transporte público solo se muestran cuando el modo activo es *transit*, evitando solapamientos visuales con las rutas viarias. La capa de fondo es configurable entre cuatro basemaps: *carto-light* (analítico, sin distracciones visuales), OpenStreetMap estándar (cartografía en color), OpenTopoMap (relieve con curvas de nivel) y satélite Esri (imágenes aéreas).

4.5. Pipeline de inferencia modal

La inferencia de elección modal es la operación más compleja del sistema porque requiere coordinar tres servicios externos de forma concurrente para construir el vector de entrada al modelo. La Figura 4.2 ilustra el flujo completo.




Figura 4.2: Pipeline de inferencia de elección modal.

Al recibir una petición `POST /api/lpmc/predict`, el backend lanza en paralelo cuatro consultas asíncronas mediante `asyncio.gather`: una a cada una de las tres instancias OSRM (conducción, bicicleta, a pie) y una a OpenTripPlanner. Con los resultados se construye el vector de características de ruta, se añaden las variables sociodemográficas del perfil recibido en la petición y se ensambla el vector completo de entrada al modelo.

Las variables de entrada se dividen en dos grupos. El primero comprende las variables de ruta, derivadas de OSRM y OTP, que caracterizan el tiempo y la distancia de cada modo para el par origen-destino concreto. El segundo comprende las variables sociodemográficas y contextuales, que el usuario introduce a través del panel lateral de la interfaz. La Tabla 4.3 describe ambos grupos.

Las variables continuas que presentaban distribución asimétrica en el conjunto de entrenamiento se normalizan con un escalado parcial aplicado solo a las columnas correspondientes, preservando las variables binarias y de conteo sin transformar. El modelo devuelve un vector de cuatro probabilidades correspondientes a los modos *walk*, *cycle*, *pt* y *drive*; el modo predicho es el de mayor probabilidad.

La variante activa del modelo se controla mediante la variable de entorno `LPMC_MODEL_VARIANT`. El valor por defecto (`nohh`) carga el modelo entrenado sin `household_id` como variable de entrada, variante apropiada para inferencia en producción ya que ese identificador no está disponible en tiempo de ejecución. La variante `legacy` mantiene compatibilidad con los artefactos originales del entrenamiento y neutraliza

Tabla 4.3: Variables de entrada al modelo de elección modal. Las variables de ruta se derivan automáticamente de OSRM y OTP; las sociodemográficas las aporta el usuario.

Variable	Tipo / Rango	Descripción
<i>Variables de ruta (derivadas de OSRM y OTP)</i>		
distance	float, m	Distancia en coche (OSRM driving).
dur_driving	float, s	Tiempo de conducción (OSRM driving).
dur_cycling	float, s	Tiempo en bicicleta (OSRM cycling).
dur_walking	float, s	Tiempo a pie hasta destino (OSRM foot).
dur_pt_access	float, s	Tiempo del primer tramo a pie hasta la parada (OTP).
dur_pt_bus	float, s	Tiempo acumulado en autobús (OTP).
dur_pt_rail	float, s	Tiempo acumulado en ferroviario (OTP).
dur_pt_int_waiting	float, s	Tiempo de espera en transbordos (OTP).
dur_pt_int_walking	float, s	Desplazamiento a pie entre transbordos (OTP).
pt_n_interchanges	int, ≥ 0	Número de transbordos (OTP).
<i>Variables sociodemográficas y contextuales (aportadas por el usuario)</i>		
age	int, [16, 100]	Edad del viajero.
female	int, {0, 1}	Sexo (1 = mujer).
driving_license	int, {0, 1}	Posesión de carnet de conducir.
car_ownership	int, [0, 3]	Número de coches en el hogar.
day_of_week	int, [1, 7]	Día de la semana.
start_time_linear	float, [0, 24]	Hora de inicio del viaje.
cost_transit	float, ≥ 0	Coste del billete de transporte público.
cost_driving_total	float, ≥ 0	Coste total estimado del viaje en coche.
purpose	cat. (one-hot)	Motivo del viaje: B, HBE, HBO, HBW, NHBO.
fueltype	cat. (one-hot)	Tipo de combustible: Average, Diesel, Hybrid, Petrol.

household_id fijándolo a cero.

4.6. Decisiones técnicas (ch5)

A lo largo del desarrollo se tomaron varias decisiones de diseño que condicionan la arquitectura actual.

OSRM local frente al servidor de demostración. La solución inicial utilizaba el demo-server público de OSRM, que solo proporciona el perfil de conducción. La imposibilidad de obtener tiempos de bicicleta y desplazamiento a pie, variables imprescindibles para el modelo LPMC, obligó a desplegar OSRM localmente con tres perfiles independientes. El coste es un mayor requisito de almacenamiento y memoria en tiempo de ejecución, compensado por la autonomía completa sobre los datos y la ausencia de límites de cuota.

Tres instancias OSRM en lugar de una. La imagen oficial de OSRM no admite múltiples perfiles en un único proceso: cada instancia solo puede servir el grafo con el que fue pre-procesada mediante `osrm-extract` y `osrm-partition`. La solución adoptada es desplegar tres contenedores independientes, cada uno con su grafo, mapeados a puertos distintos del host.

Fecha y hora fijas en OTP. OpenTripPlanner calcula itinerarios en función de los calendarios de servicio del feed GTFS. Usar la fecha y hora reales introducía inconsistencias: en fines de semana o festivos el servicio es reducido o inexistente, lo que hacía que OTP devolviera itinerarios atípicos o ninguno. La solución adoptada es usar una fecha laborable fija (2025-12-01) y una hora de alta frecuencia de servicio (12:00), garantizando resultados representativos del servicio habitual.

Variante nohh del modelo LPMC. El modelo original incluía `household_id` como variable de entrada, lo que imposibilita su uso en inferencia ya que el simulador no tiene acceso a ese identificador. Se entrenó una variante alternativa excluyendo esa variable (`nohh`), que es la activa por defecto. La variante original se conserva como respaldo y el sistema puede alternar entre ambas mediante variable de entorno.

Colores de línea GTFS deterministas. El feed GTFS de Toledo no incluye de forma consistente los campos `route_color` y `route_text_color`. Para garantizar consistencia visual entre sesiones, el color de cada línea se deriva de forma determinista a partir del `route_id` mediante una función de hash, de modo que la misma línea siempre se muestra con el mismo color independientemente del estado del servidor.

Carga perezosa de artefactos del modelo. El modelo XGBoost y el escalador se cargan desde disco la primera vez que se recibe una petición de inferencia y se mantienen en caché

a nivel de módulo durante toda la vida del proceso. Esta estrategia de carga perezosa (*lazy loading*) evita aumentar el tiempo de arranque del contenedor y garantiza que los artefactos se cargan exactamente una vez, independientemente del número de peticiones concurrentes que sirva el servidor.

Penalización de variables PT sin itinerario real. Cuando OTP no encuentra un itinerario con transporte público, las variables de ruta PT (`dur_pt_access`, `dur_pt_bus`, `dur_pt_rail`, `pt_n_interchanges`) toman valor cero, lo que puede inducir al modelo a predecir *pt* como modo mayoritario en trayectos sin servicio real. La solución, pendiente de implementar en el momento de escritura, consiste en asignar un valor de penalización alto a estas variables cuando OTP no devuelva un itinerario con al menos un tramo de transporte público.

5. Implementación y resultados

5.1. Implementación de OSRM local

5.1.1. Preprocesado por perfiles

Car, bike y foot

5.1.2. Despliegue de contenedores

Puertos y verificación

5.2. Implementación de OTP con Toledo

5.2.1. Construcción de grafo

Entradas OSM y GTFS

5.2.2. Explotación del planificador

Parámetros relevantes

5.3. Implementación del backend

5.3.1. Endpoints y servicios

OSRM, OTP y GTFS

5.4. Implementación del frontend

5.4.1. Interfaz y mapa interactivo

Flujos de usuario

5.5. Integración de datos GTFS

5.5.1. Carga y procesamiento

Rutas, paradas y horarios

5.6. Entrenamiento de los modelos de aprendizaje automático

5.6.1. Descripción del dataset

LPMC

5.6.2. Preprocesado de datos

5.6.3. Ajuste de hiperparámetros

5.6.4. Entrenamiento y evaluación

Tabla 5.1: Resultados en entrenamiento con validación cruzada de 5-folds agrupada por hogar (dataset LPMC)

Modelo	Accuracy (%)	GMPCA (%)
Random Forest	74.87	51.18
XGBoost	75.48	52.54
DNN	74.66	52.06

Tabla 5.2: Resultados en el conjunto de test (dataset LPMC)

Modelo	Accuracy (%)	GMPCA (%)
Random Forest	74.10	50.33
XGBoost	74.41	51.63
DNN	73.84	51.06

6. Conclusiones y trabajo futuro

6.1. Conclusiones técnicas

6.2. Cumplimiento de objetivos

6.3. Trabajo futuro

A. Anexos

A.1. Manual de despliegue y ejecución

A.1.1. Requisitos del entorno

Versiones recomendadas

A.1.2. Arranque de servicios

OSRM, OTP, backend y frontend

A.2. Endpoints y contratos API

A.2.1. Contratos del backend

Ejemplos de petición y respuesta

A.3. Tablas de hiperparámetros y resultados completos

A.3.1. Configuraciones experimentales

Resultados detallados por experimento

A.4. Evidencias de sprints

A.4.1. Registro de tareas y decisiones

Referencias a commits y artefactos